阶段 1 参考资料与固定版本

本目录保存阶段 1 实际使用的公开参考资料。论文 PDF 用于个人学习和离线查阅；正式引用时请回到对应的 arXiv/官方页面核对版本。代码仓库保留其原始 LICENSE，不在其中混入本阶段练习代码。

资料清单

本地资料	来源	本阶段用途
`nanoGPT/`	karpathy/nanoGPT	追踪字符数据、GPT block、训练循环和生成入口
`Attention_Is_All_You_Need.pdf`	arXiv:1706.03762	scaled dot-product attention、multi-head attention、decoder mask 的原始背景
`GPT2_Language_Models_are_Unsupervised_Multitask_Learners.pdf`	OpenAI GPT-2 paper PDF	decoder-only language modeling 与 next-token likelihood 的历史背景
`SentencePiece_A_simple_and_language_independent_subword_tokenizer.pdf`	arXiv:1808.06226	子词 tokenizer、raw text 训练和可逆边界的工程直觉

仓库版本

`nanoGPT` 当前固定为浅克隆得到的 commit `3adf61e`（2025-11-12）。当前仓库 README 已说明 nanoGPT 属于旧项目并推荐关注其后续项目；本阶段仍选择它，是因为代码短、端到端路径清楚。不要把本地快照当成最新推理框架。

建议只按以下入口阅读：

```
README.md
config/train_shakespeare_char.py
configurator.py
data/shakespeare_char/prepare.py
model.py: GPTConfig → CausalSelfAttention → MLP → Block → GPT.forward → GPT.generate
```

```
train.py
sample.py
```

阅读时的版本边界

- nanoGPT 的默认字符实验依赖其自己的数据准备脚本；本阶段不自动下载 Shakespeare 数据，也不运行大规模配置。
- nanoGPT 的 attention 可能根据 PyTorch 版本选择 fused/flash 路径或手写 mask 路径；先核对二者的数学语义，再看性能。
- `from_pretrained` 等路径会引入额外依赖；阶段 1 的独立程序只依赖当前 `agent/.venv` 中已有的 PyTorch 和 NumPy。
- 论文中的实验规模、硬件和训练结论不能直接外推到本目录的极小字符模型。

下载来源记录

```
仓库：https://github.com/karpathy/nanoGPT.git
Transformer：https://arxiv.org/pdf/1706.03762
GPT-2：https://cdn.openai.com/better-language-
models/language_models_are_unsupervised_multitask_learners.pdf
SentencePiece：https://arxiv.org/pdf/1808.06226
```

若重新下载，先记录新的 commit、下载日期和 SHA-256，再更新此文件；不要无记录地覆盖参考版本。

当前文件校验值

以下 SHA-256 是本地资料包当前文件的校验值（记录日期：2026-10-25）：

```
Attention_Is_All_You_Need.pdf
BDFAA68D8984F0DC02BEACA527B76F207D99B666D31D1DA728EE0728182DF697

GPT2_Language_Models_are_Unsupervised_Multitask_Learners.pdf
D9D852E2894556E73F53CB22B7C605A9643D6F0B19BF604B429ED6192FA24F4E

SentencePiece_A_simple_and_language_independent_subword_tokenizer.pdf
8A81EB8BF88F063348356E744AFE9E72B305393612F7D4A35596C2701588838D
```

校验命令：

```
Get-FileHash '.\阶段1_decoder_only生成与nanoGPT\参考资料\Attention_Is_All_You_Need.pdf' -
Algorithm SHA256
Get-FileHash '.\阶段1_decoder_only生成与nanoGPT\参考资料
\GPT2_Language_Models_are_Unsupervised_Multitask_Learners.pdf' -Algorithm SHA256
Get-FileHash '.\阶段1_decoder_only生成与nanoGPT\参考资料
\SentencePiece_A_simple_and_language_independent_subword_tokenizer.pdf' -Algorithm SHA256
```